DISTRIBUIRANI ALGORITMI I SISTEMI

Iz kursa CSCE 668
Proleće 2014

Autor izvorne prezentacije:
Prof. Jennifer Welch

Distribuirana deljena memorija

- Jedan model međuprocesne komunikacije
- Obezbeđuje iluziju deljenih promenljivih na vrhu sistema za slanje poruka
- Deljena memorija se obično smatra pogodnijom platformom od sistema za slanje poruka
- Formalno, to je simulacija modela deljene memorije na vrhu modela sa slanjem poruka
- Posmatraćemo poseban slučaj:
  - nema otkaza
  - simuliraju se samo promenljive sa operacijama čitaj/piši

Simulacija

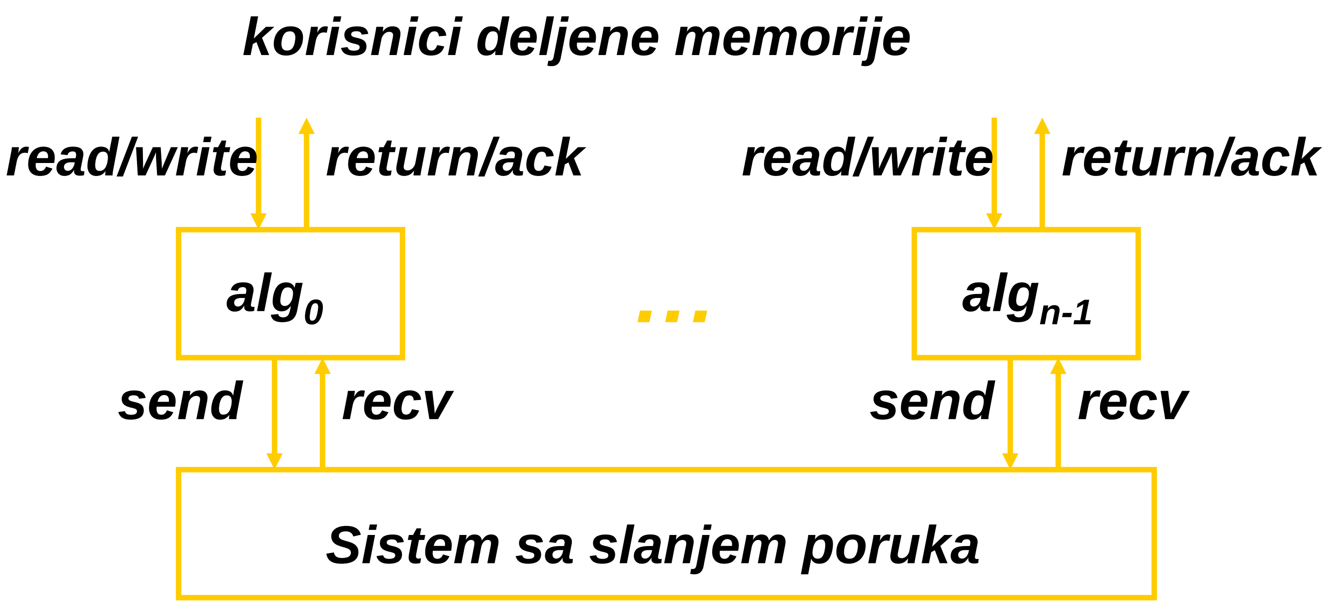
korisnici deljene memorije
read/write
return/ack
read/write
return/ack
alg_0
...
alg_{n-1}
send
recv
send
recv
Sistem sa slanjem poruka

Problemi deljene memorije

- Proces poziva operaciju deljene memorije (čitaj ili piši) u nekom trenutku
- Simulacioni algoritam na nekom čvoru izvršava neki kod, uz moguću razmenu poruka
- Na kraju simulacioni algoritam informiše proces o rezultatu pozvane operacije
- Znači operacije deljene memorije nisu trenutne!
  - Operacije (pozvane od raznih procesa) se mogu preklapati
- Koje vrednosti treba da vrate operacije koje se preklapaju sa drugim operacijama?
  - to definiše **uslov memorijske konzistentnosti**

Sekvencijalne specifikacije

- Svaki deljeni objekt ima **sekvencijalnu spec.**: specificira ponašanje objekta u *odsustvu* konkurencije
- Objekt podržava **operacije**:
  - pozive
  - odgovarajuće odgovore
- Skup sekvenci operacija koje su **legalne**

Sekvencijalna specifikacija za R/W registre

- Svaka operacija ima dva dela, poziv i odgovor
- Operacija read ima poziv $read_i(X)$ i odgovor $return_i(X,v)$ (indeks *i* odgovara procesu)
- Operacija write ima poziv $write_i(X,v)$ i odgovor $ack_i(X)$ (indeks *i* odgovara procesu)
- Sekvenca operacija je legalna ako i samo ako svako čitanje vraća vrednost poslednjeg prethodnog upisa
- Npr.: $[write_0(X,3)\ ack_0(X)]\ [read_1(X)\ return_1(X,3)]$

Uslovi memorijske konzistentnosti

- Uslovi konzistentnosti povezuju sekvencijalnu specifikaciju sa onim što se dešava u prisustvu konkurencije
- Proučićemo dva dobro-poznata uslova:
  - mogućnost linearizacije (linearizability)
  - sekvencijalna konzistentnost
- Razmotićemo samo registre za čitanje/upis, u slučaju kada nema otkaza

Definicija mogućnosti linearizacije (Linearizability)

- Neka je σ sekvenca poziva i odgovora za skup operacija
  - poziv ne mora biti odmah praćen svojim odgovorom, može imati konkurentne, preklapajuće operacije
- σ se **može linearizovati** ako postoji permutacija π svih *operacija* u σ (gde je svaki poziv odmah praćen svojim odgovorom), koji zadovoljava:
  - π|*X* je legalna (zadovoljava sekve. spec.) za sve prom. *X*, i
  - ako se odgovor za operaciju O_1 desio u σ pre poziva operacije O_2, onda se O_1 desila u π pre O_2 (π respektuje redosled realnog vremena nepreklopljenih operacija u σ)

Primeri mogućnosti linearizacije

Neka postoje dve deljene promenljive, *X* i *Y*, obe inicijalno 0

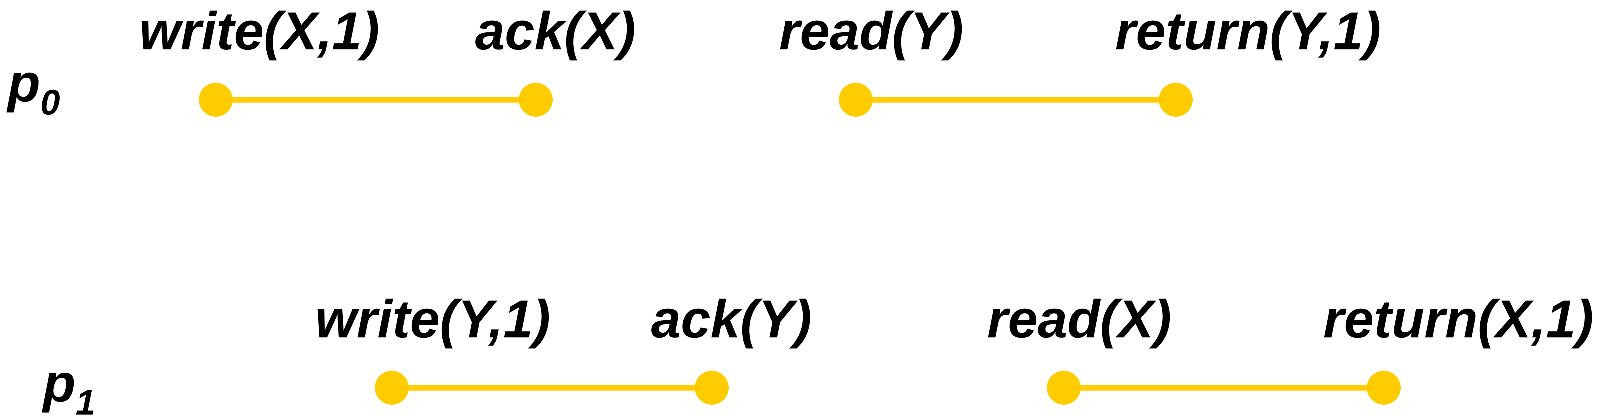

Primeri mogućnosti linearizacije

Neka postoje dve deljene promenljive, *X* i *Y*, obe inicijalno 0

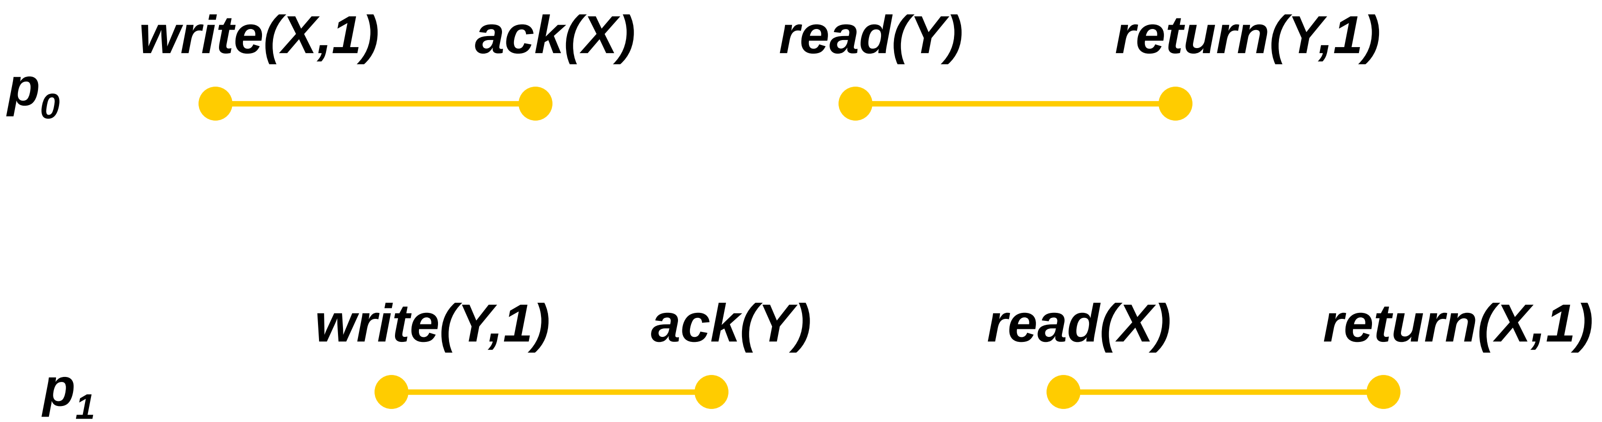

Da li se ova sekvenca
može linearizovati?

Primeri mogućnosti linearizacije

Neka postoje dve deljene promenljive, *X* i *Y*, obe inicijalno 0

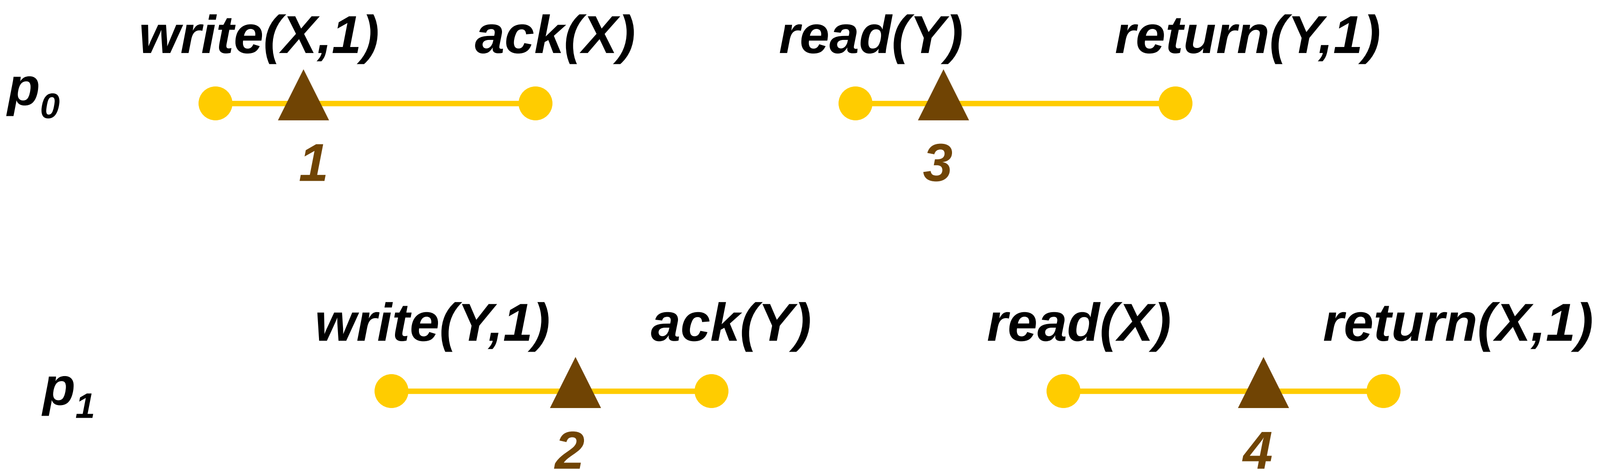

Da li se ova sekvenca može linearizovati?

Da – braon trouglovi.

Primeri mogućnosti linearizacije

Neka postoje dve deljene promenljive, *X* i *Y*, obe inicijalno 0

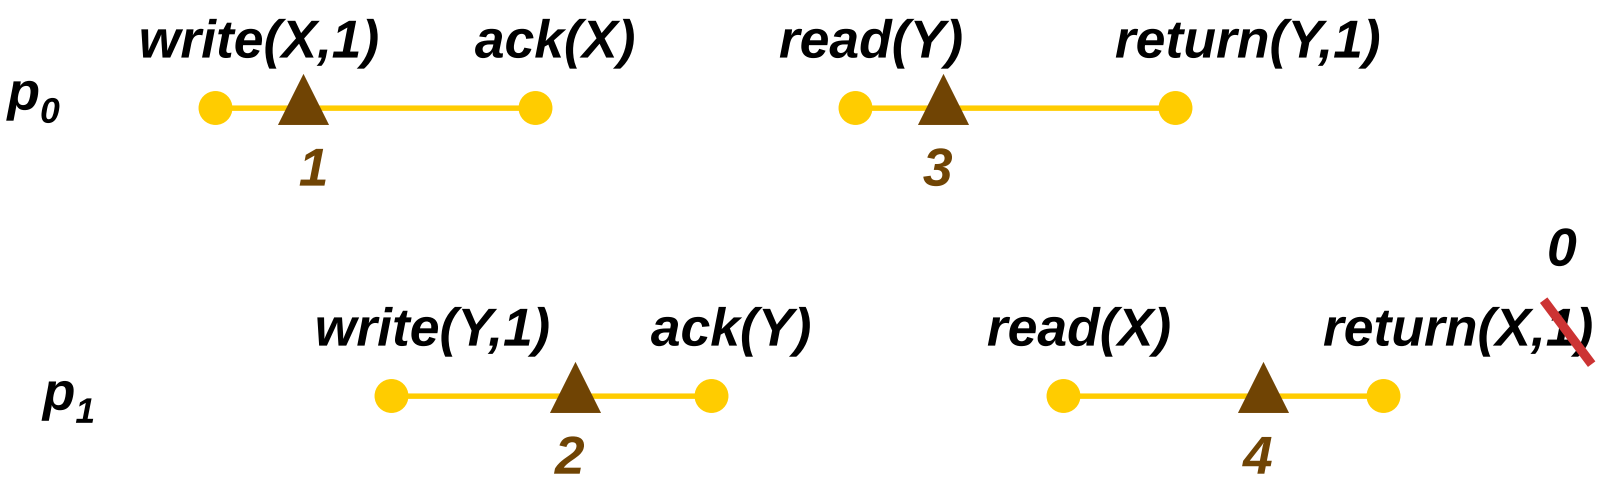

Da li se ova sekvenca može linearizovati?

Da – braon trouglovi.

Šta ako read od p_1 vrati 0?

Primeri mogućnosti linearizacije

Neka postoje dve deljene promenljive, *X* i *Y*, obe inicijalno 0

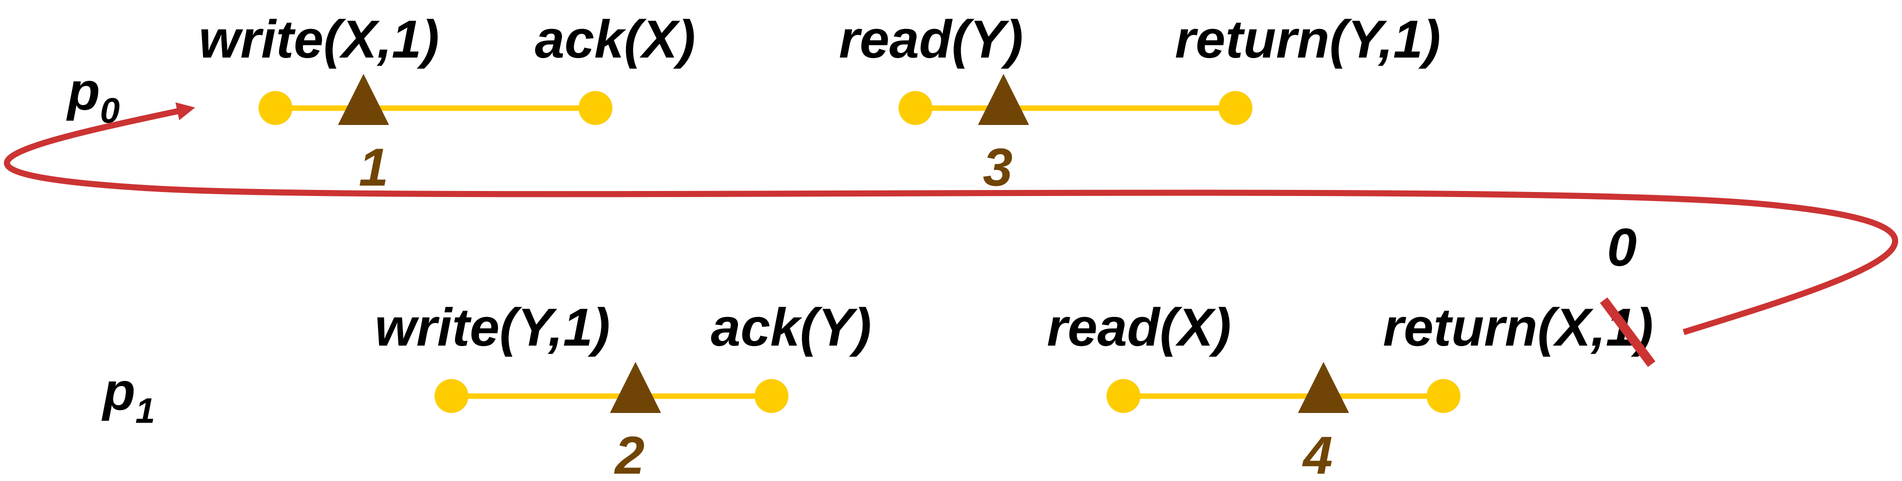

Da li se ova sekvenca može linearizovati?

Da – braon trouglovi.

Šta ako read od p_1 vrati 0?

Ne – vidi strelicu.

Definicija sekve. konzistentnosti (Sequential Consistency)

- Neka je σ sekvenca poziva i odgovora za neki skup operacija
- σ je **sekve. konzistentna** ako postoji permutacija π svih operacija u σ takva da:
  - $\pi | X$ je legalna (zadovoljava sekve. spec.) za sve prom. X, i
  - ako se odgovor za operaciju O_1 desio u σ pre poziva operacije O_2 *u istom procesu*, onda se O_1 desila u π pre O_2 (π respektuje redosled realnog vremena operacija *od strane istog procesa* u σ)

Primeri sekvencijalne konzistentnosti

Neka postoje dve deljene promenljive, *X* i *Y*, obe inicijalno 0

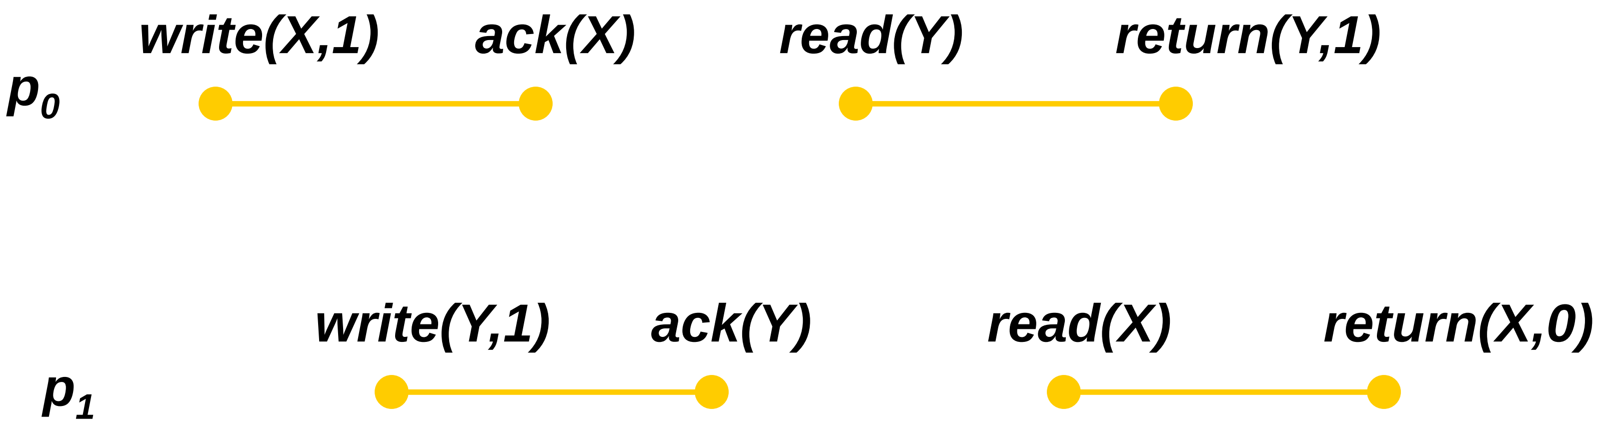

Primeri sekvencijalne konzistentnosti

Neka postoje dve deljene promenljive, *X* i *Y*, obe inicijalno 0

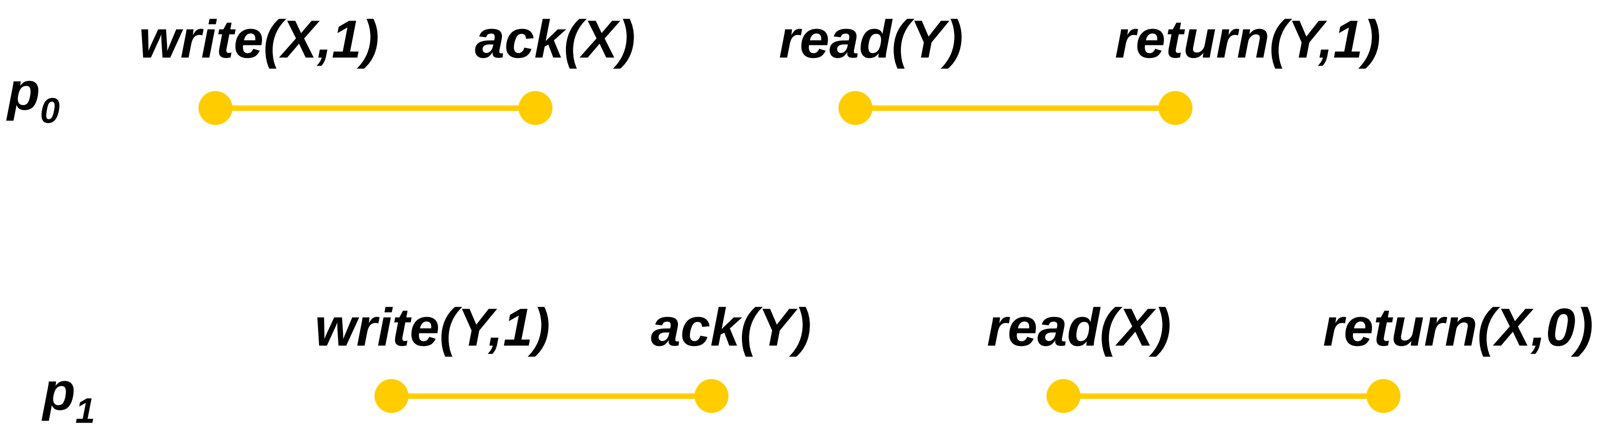

Da li je ova sekvenca sekve. konzistenta?

Primeri sekvencijalne konzistentnosti

Neka postoje dve deljene promenljive, *X* i *Y*, obe inicijalno 0

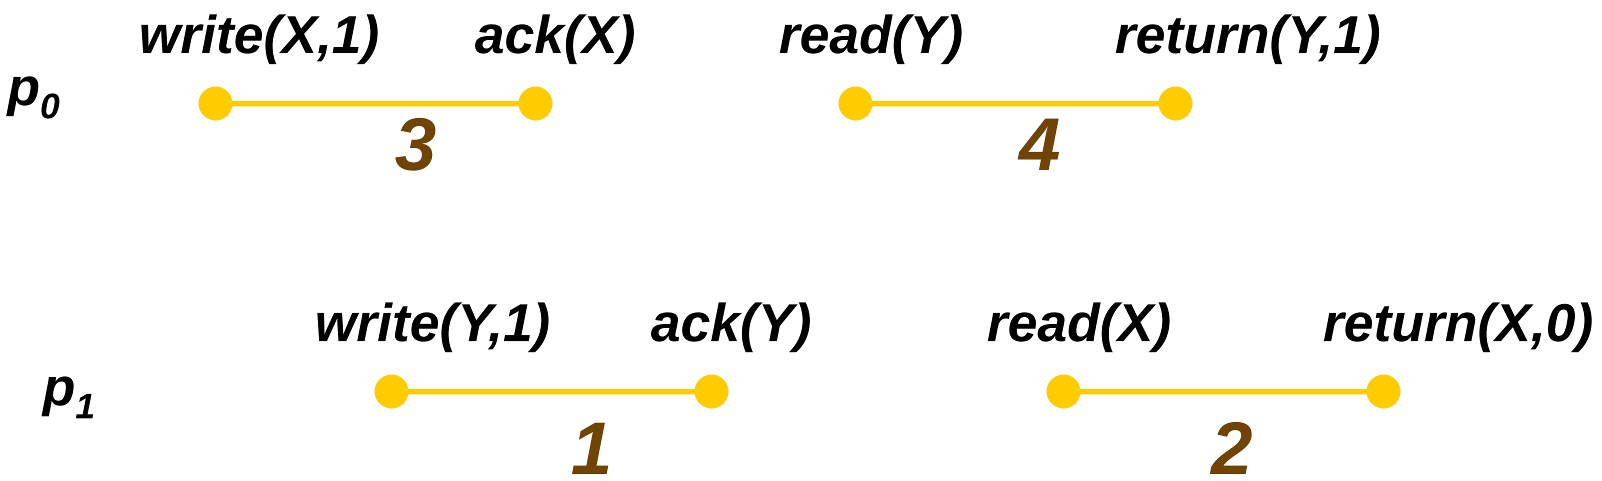

Da li je ova sekvenca sekve. konzistenta? Da – braon brojevi.

Primeri sekvencijalne konzistentnosti

Neka postoje dve deljene promenljive, *X* i *Y*, obe inicijalno 0

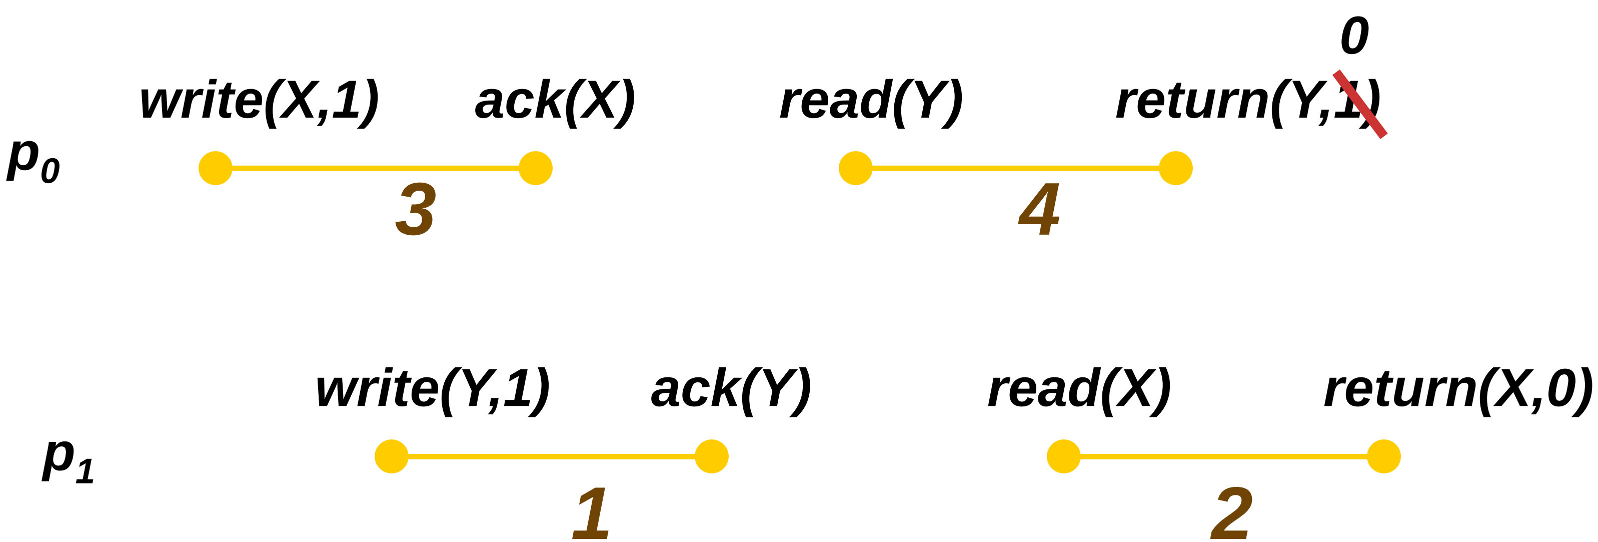

Da li je ova sekvenca sekve. konzistenta? Da – braon brojevi.

Šta ako read od p_1 vrati 0?

Primeri sekvencijalne konzistentnosti

Neka postoje dve deljene promenljive, *X* i *Y*, obe inicijalno 0

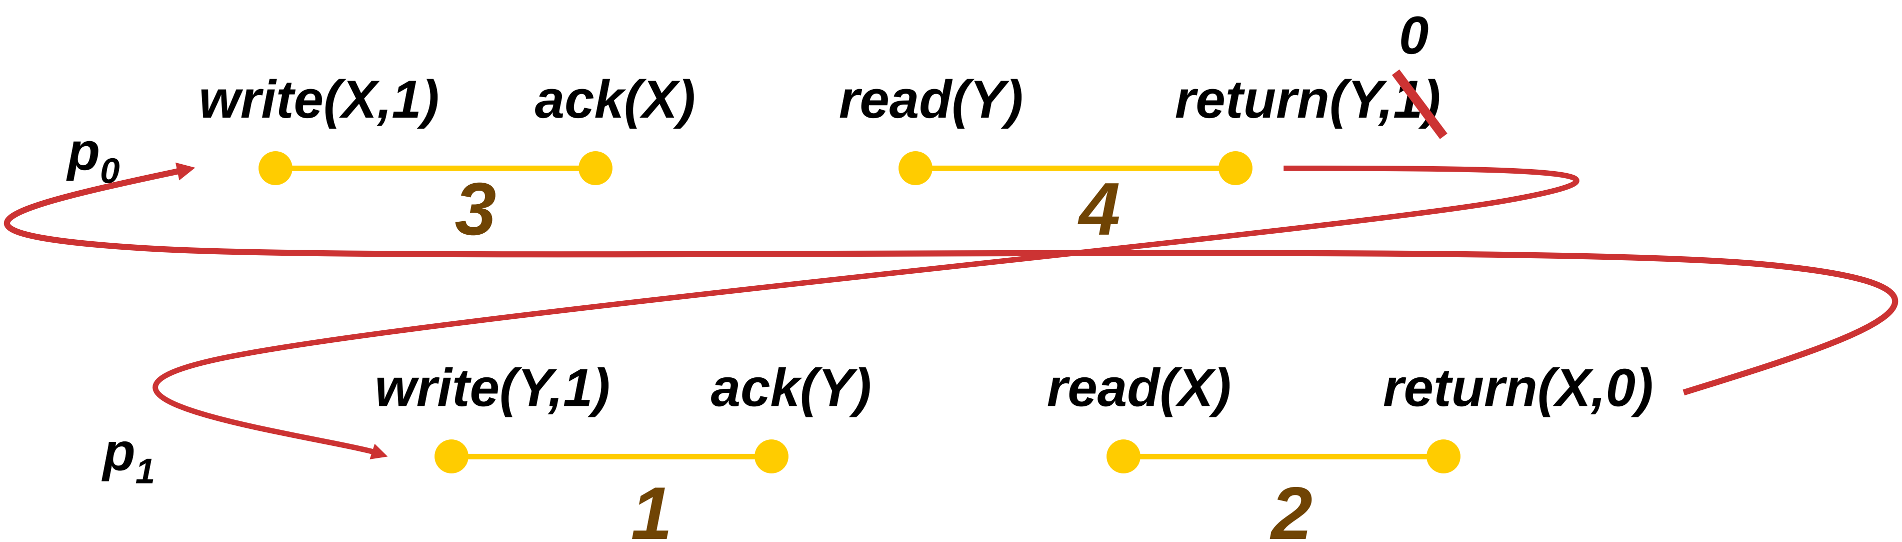

Da li je ova sekvenca sekve. konzistenta? Da – braon brojevi.

Šta ako read od p_1 vrati 0? Ne – vidi strelice.

Specifikacija deljene memorije čije sekvence se mogu linearizovati

- Ulazi su pozivi operacija deljenih objekata
- Izlazi su odgovori iz deljenih objekata
- Sekvenca σ je u dopuštenom skupu ako i samo ako:
  - *Korektna interakcija:* svaki proc. ima naizmenične pozive i odgovarajuće odzive
  - *Životnost:* svaki poziv ima odgovarajući odgovor
  - *Mogućnost linearizacije:* σ se može linearizovati

Specifikacija deljene memorije koja je sekvencijalno konzistentna

- Ulazi su pozivi operacija deljenih objekata
- Izlazi su odgovori iz deljenih objekata
- Sekvenca σ je u dopuštenom skupu ako i samo ako:
  - *Korektna interakcija:* svaki proc. ima naizmenične pozive i odgovarajuće odzive
  - *Životnost:* svaki poziv ima odgovarajući odgovor
  - *Sekvencijalna konzistentnost:* σ je sekvencijalno konzistentna

Algoritam deljene memorije čije sekvence se mogu linearizovati

- Koristi slanje poruke svima (broadcast) u skladu sa totalnim redosledom (total order)
- Svaki proc održava repliku za svaku deljenu promenljivu
- Kad stigne zahtev za čitanje:
  - pošalji bcast por. koja sadrži zahtev
  - kad stigne sopstvena bcast por., vrati vrednost lokalne replike
- Kad stigne zahtev za pisanje:
  - pošalji bcast por. koja sadrži zahtev
  - nakon prijema, svaki proc ažurira svoju repliku
  - kad stigne sopstvena bcast por., odgovori sa ack

Simulacija

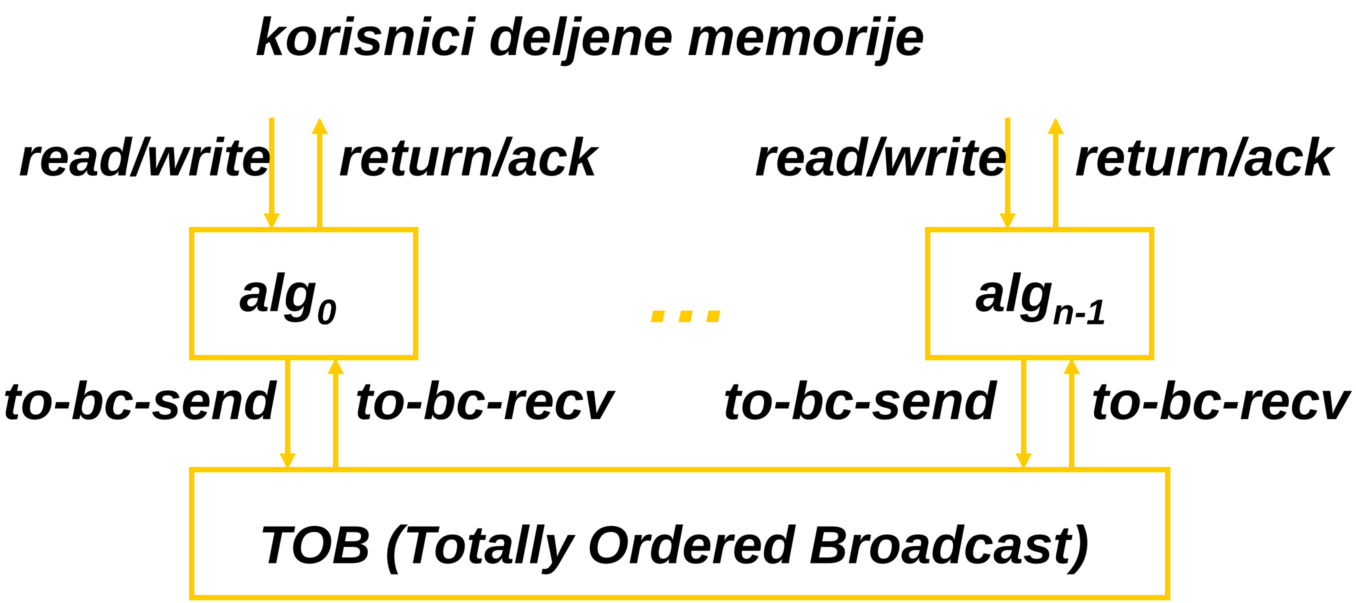
korisnici deljene memorije
read/write
return/ack
read/write
return/ack
alg_0
...
alg_{n-1}
to-bc-send
to-bc-recv
to-bc-send
to-bc-recv
TOB (Totally Ordered Broadcast)

Korektnost ovog algoritma

- Neka je α bilo koje prihvatljivo izvršenje algoritma za koje važi:
  - slanje poruka svima u skladu sa totalnim redosledom radi ispravno
  - korisnička interakcija je ispravna (naizmenični pozivi i odgovori)
- Pokazati da σ (restrikcija α na događaje na vrhu interfejsa) zadovoljava Životnost i Mogućnost linearizacije

Korektnost ovog algoritma

- Životnost (svaki poziv ima svoj odgovor): po svojstvu životnosti TOB (Totally Ordered Broadcast)
- Mogućnost linearizacije: Definišimo permutaciju operacija π da bude u redosledu u kom su odgovarajuće bcast por. primljene:
  - π je legalna: jer su sve operacije konzistentno poređane po TOB.
  - π respektuje redosled operacije u realnom vremenu: ako se O_1 završi pre nego O_2 počne, bcast od O_1 se obavlja pre bcast od O_2

Zašto je potrebno slanje svima (Bcast) kod operacije čitanja?

- Slanje svima kod read operacije ne izaziva promene replika, samo kasni odgovore na read op
- Zašto je ono ipak potrebno?
- Pogledajmo šta se dešava ako ga uklonimo

Zašto je read bcast neophodan?

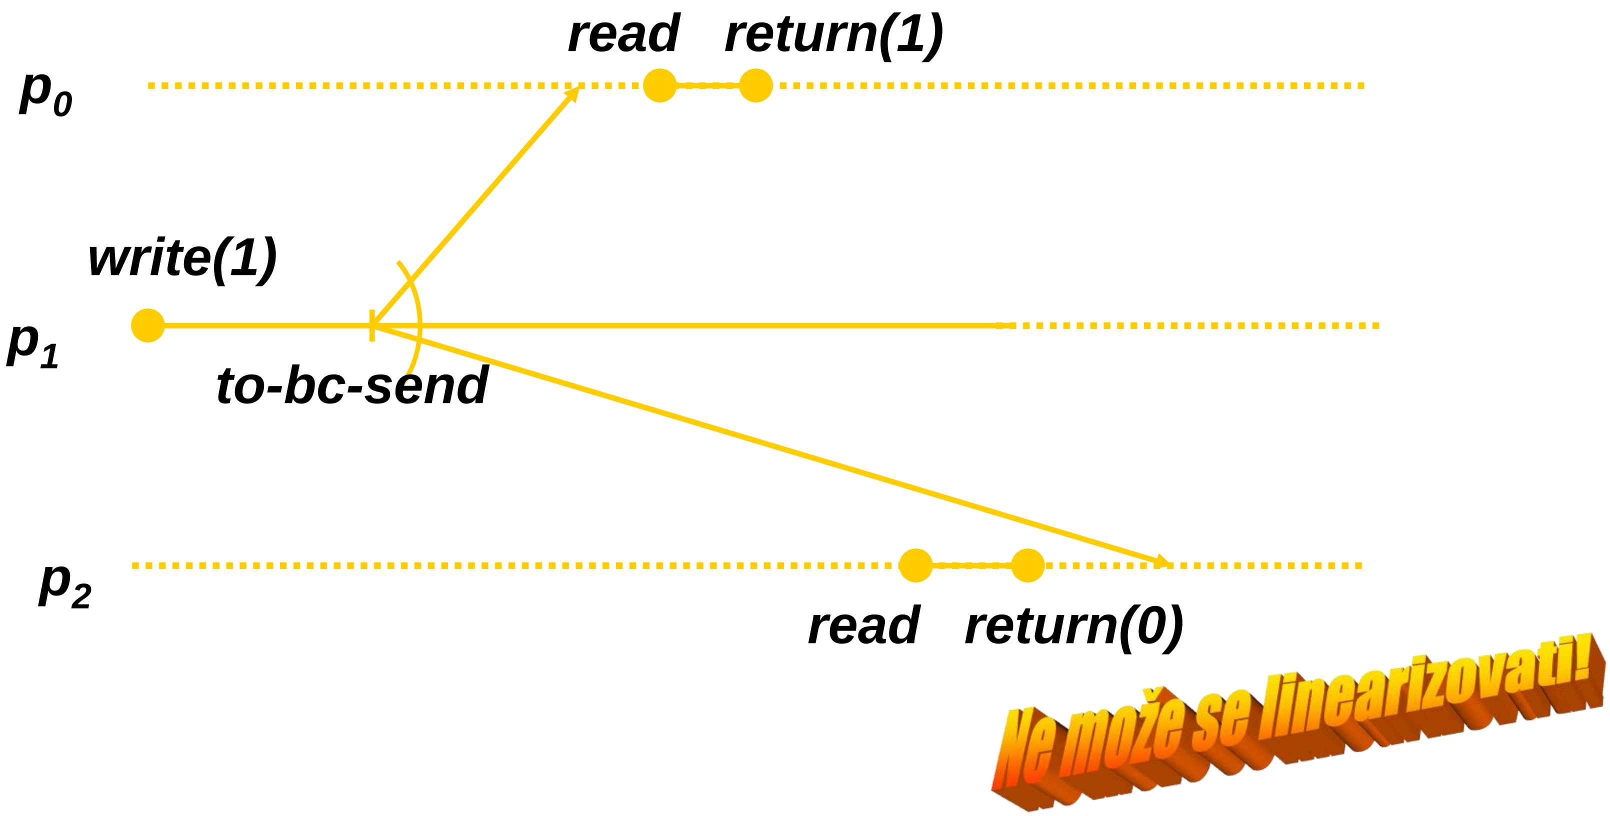

Algoritam za sekvencijanu konzistentnost (SC algoritam)

- Kao predhodni algoritam, ali bez bcast za čitanja:
- Koristi TOB
- Svaki procesor održava repliku svake deljene promenljive
- Kad stigne zahtev za čitanje:
  - odmah vrati vrednost lokalne replike
- Kad stigne zahtev za pisanje:
  - pošalji bcast por. koja sadrži zahtev
  - nakon prijema, svaki proc ažurira svoju repliku
  - kad stigne sopstvena bcast por., odgovori sa ack

Korektnost SC algoritma

Lema (8.3): Lokalne kopije svakog proc. uzimaju sve vrednosti iz write operacija, u istom redosledu, koji očuvava redosled nepreklopljenih write operacija

- implicira da je redosled write op po proc. očuvan

Lema (8.4): Ako p_i piše u *Y* i kasnije čita *X*, onda p_i-jevo ažuriranje njegove lokalne kopije *Y* (unutar write op) predhodi njegovom čitanju svoje lokalne kopije *X* (unutar read op)

Korektnost SC algoritma

(Teorema 8.5) Zašto važi SC?

- Za bilo koje prihvatljivo izvršenje α, moramo doći do permutacije π operacija deljene mem. koja je:
  - legalna i
  - respektuje redosled operacija po proc.

Permutacija π

- Ubacite sve write op u π u njihovom TOB redosledu
- Razmotrimo svaki read R u α u redosledu poziva:
  - neka je R čitanje X od p_i
  - stavi R u π odmah iza poslednje od ove 2 op:
    1. operacija od p_i koja neposredno predhodi R u α, i
    2. Write op „iz koje R čita“ (izaziva poslednje ažuriranje p_i -jeve lokalne kopije X, koje predhodi odgovoru za R)

Primer permutacije

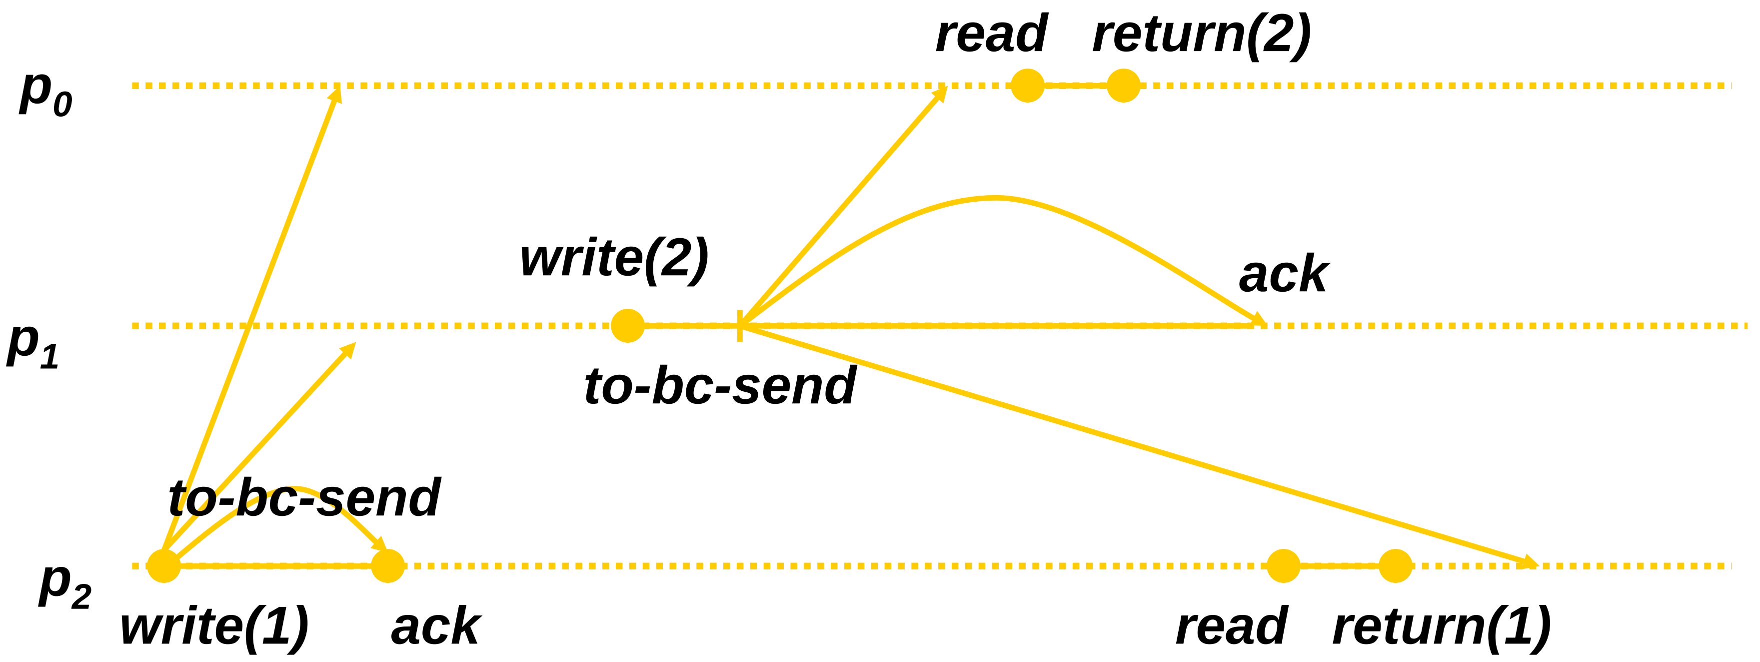

Primer permutacije

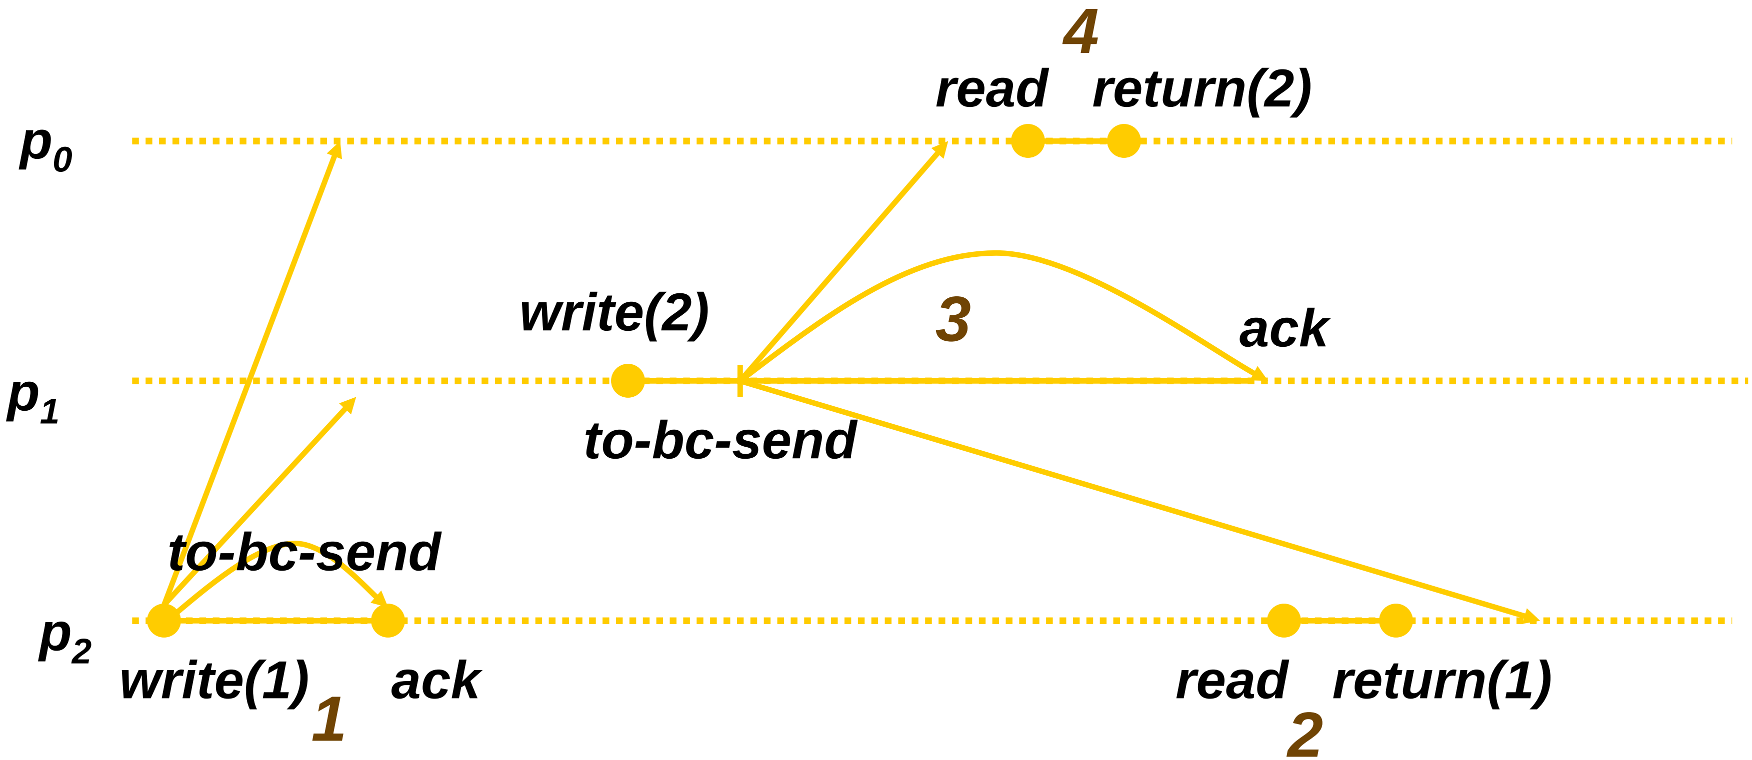

permutacija je data sa braon brojevima

Permutacija π respektuje redosled po proc.

Za određeni proc:

- Relativan redosled dva write-a je očuvan po Lemi 8.3
- Relativan redosled dva read-a je očuvan načinom konstruisanja π
- Ako write W predhodi read-u R u izvrše. α, onda W predhodi R u π po konstrukciji
- Neka read R predhodi write-u W u α.
  Pokažimo da isto važi u π.

Permutacija π respektuje redosled

- Pred. radi kontradikcije da su R i W zamenili mesta u π:
  - Postoji read R' od p_i koji je jednak ili predhodi R u α
  - Postoji write W' koji je jednak W ili prati W u TOB redosledu
  - R' „čita iz“ W'

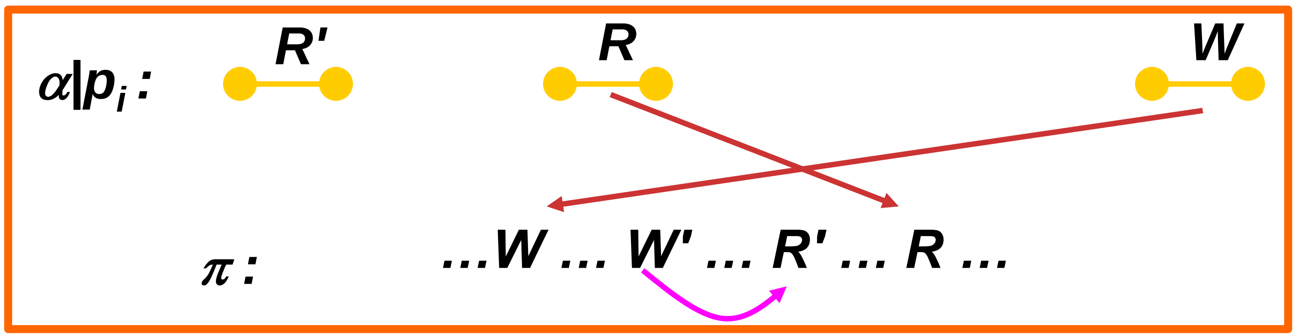

- Ali:
  - R' se završava pre nego W počne u α i
  - ažuriranja lokalnih replika su u TOB redosledu (Lema 8.3) pa ažuriranje za W' ne predhodi ažuriranju za W
  - zato R' ne može da čita iz W'

Permutacija π je legalna

- Razmotrimo neki read R iz X od p_i i neki write W koji zadovoljava da R čita iz W u α
- Pred. radi kontradikcije, da neki drugi write W′ u X pada između W i R u π:

π : ...W ... W' ... R ...

- Da li R zaista može da prati W′ u π?

Permutacija π je legalna

Slučaj 1: W' je isto od p_i. Onda R prati W' u π zato što R prati W' u α

- Ažuriranje za W u p_i predhodi ažuriranje za W' u p_i u α (Lema 8.3).
- Zato R ne čita iz W, kontradikcija

Permutacija π je legalna

Slučaj 2: W' nije od p_i. Onda R prati W' u π zbog neke operacije O, takođe od p_i, koja zadovoljava:

- O predhodi R u α, i
- O je postavljena između W' i R u π

Razmotrimo najraniju takvu O

π : ...W ... W' ... O ... R ...

Slučaj 2.1: O je neki write (ne mora biti u X)

- ažuriranje za W' u p_i predhodi ažuriranju za O u p_i u α (Lema 8.3)
- ažuriranje za O u p_i predhodi lokal. čitanju u p_i za R u α (Lema 8.4)
- Znači R ne čita iz W, kontradikcija

Permutacija π je legalna

π : ...W ... W' ... O ... R ...

Slučaj 2.2: O je read

- Po konstrukciji π, O mora da čita *X* i u stvari čita iz W' (inače O ne bi bio posle W')
- Ažuriranje za W u p_i predhodi ažuriranju za W' u p_i u α (Lema 8.3).
- Ažuriranje za W' u p_i predhodi lokalnom čitanju za O u p_i u α (inače O ne bi čitao iz W').
- Zato *R* ne može da čita iz W, kontradikcija

Performansa SC algoritma

- Read operacije su implementirane „lokalno“, i ne zahtevaju međuprocesnu komunikaciju
- Zato se read op može posmatrati kao „brza“: vreme između poziva i odgovora je vreme lokane obrade
- Vreme za write op je vreme isporuke jedne to-bcast por (zavisi od implementacije to-bcast)

Alternativni SC algoritam

- Postoji alternativni alg koji ima obrnutu performansu:
  - write op je lokalna/brza (iako se šalju bcast-ovi, ne čeka se da oni budu primljeni)
  - read op može zahtevati da neki bcast-ovi budu primljeni
- Kao i predhodni SC algoritam, ni ovaj ne obezbeđuje mogućnost linearizacije sekvence op deljene memorije

Vreme izvršenja DSM algoritama

- Jedna važna mera složenosti DSM algoritama je vreme potrebno da se operacije završe
- Algoritam koji omogućava lineraizaciju zahteva *D* vremena za read i write op (D vremena za svaku), gde je *D* max vreme potrebno da se to-bcast poruka primi
- SC algoritam zahteva *D* vremena za write i *0* za read op, jer je vreme lokalne obrade zanemarljivo
- Da li postoji bolje rešenje? Da bi mogli da odgovorimo, treba nam neka vrsta vremenskog modela

Vremenski model

- Neka je sistem za slanje poruka tipa od-tačke-do-tačke (*nije* to-bcast)
- Neka svaka poruka ima kašnjenje u opsegu [*d-u*,*d*]
- *Tvrdnja:* to-bcast se može implementirati u ovom modelu tako da *D*, max vreme isporuke, bude O(*d*)

Donja granica za SC

Neka je T_{read} = najduže vreme (WCT) za read op

Neka je T_{write} = najduže vreme (WCT) za write op

Teorema (8.7): U bilo kojoj simulaciji SC deljene memorije na vrhu sistema za slanje poruka tipa od-tačke-do-tačke važi: $T_{read} + T_{write} \geq d$

Donje granice za write i read u alg. koji omogućava linearizaciju

Teorema (8.8): U svakoj simulaciji SM sa mogućom linearizacijom, na vrhu sistema od-tačke-do-tačke, $T_{write} \geq u/2$.

Teorema (8.9): U svakoj simulaciji SM sa mogućom linearizacijom, na vrhu sistema od-tačke-do-tačke, $T_{read} \geq u/4$.